

Sistema de apoyo a la decisión basado en predicción de demanda para la gestión de inventarios

Danna Andrea Rodriguez Galarcio

Trabajo de grado presentado para optar al título de ingeniero de sistemas

Asesor:

Ivan Mauricio Cabezas



Universidad de San Buenaventura

Facultad de Ingeniería (Cali)

Ingeniería Sistemas

Santiago de Cali, Colombia

2026

Citar/How to cite	Nombre . [1]
Referencia/Reference	[1] Nombre . “Sistema de apoyo a la decisión basado en predicción de demanda para la gestión de inventarios”, Trabajo de grado profesional , Ingeniería Sistemas , Universidad de San Buenaventura Santiago de Cali, Colombia , 2026 .
Estilo/Style:	
IEEE (2020)	



**Repositorio
Institucional**
Universidad de San Buenaventura

Biblioteca Digital (Repositorio)
www.bibliotecadigital.usb.edu.co

Bibliotecas Universidad de San Buenaventura

Biblioteca Fray Alberto Montealegre O.F.M. - Bogotá.

Biblioteca Fray Arturo Calle Restrepo O.F.M. - Medellín, Bello, Armenia, Ibagué.

Departamento de Biblioteca - Cali.

Biblioteca Central Fray Antonio de Marchena – Cartagena.

Universidad de San Buenaventura Colombia - www.usb.edu.co

Bogotá - www.usbbog.edu.co

Medellín - www.usbmed.edu.co

Cali - www.usbcali.edu.co

Cartagena - www.usbctg.edu.co

Editorial Bonaventuriana - www.editorialbonaventuriana.usb.edu.co

Revistas científicas – www.revistas.usb.edu.co

Dedicatoria

Texto de dedicatoria centrado.

Agradecimientos

Texto de agradecimientos centrado.

TABLA DE CONTENIDO

LISTA DE TABLAS

LISTA DE FIGURAS

RESUMEN

resumen *Palabras clave* — **Predicción de demanda, gestión de inventarios, sistemas de apoyo a la decisión, series de tiempo**

El presente proyecto tiene como objetivo desarrollar un sistema de apoyo a la decisión orientado a la predicción de la demanda de productos en los inventarios.

Esta problemática surge a partir de la falta de información precisa sobre las cantidades necesarias de productos, lo cual dificulta la correcta planificación y puede llevar a que halla desabastecimiento, afectando negativamente la atención de los clientes.

Para abordar esta situación, en este trabajo se propone el uso de modelos de predicción basados en datos históricos de consumo. El sistema permitirá estimar las cantidades requeridas de productos cada mes, así como generar indicadores que apoyen la toma de decisiones para los encargados del manejo del inventario, tales como puntos de reposición y alertas.

Metodológicamente, se emplean diferentes técnicas y enfoques de la ingeniería de sistemas para obtener esta herramienta funcional, que contribuya a mejorar la gestión del inventario, optimizar la planificación de compras y reducir el riesgo de desabastecimiento.

ABSTRACT

Abstract *Keywords* — **Demand forecasting, inventory management, decision support systems, time series** The objective of this project is to develop a decision support system designed to predict demand for products in inventory.

This problem arises from a lack of accurate information regarding the required quantities of products, which hinders proper planning and can lead to shortages, negatively affecting customer service.

To address this situation, this study proposes the use of forecasting models based on historical consumption data. The system will enable the estimation of the required quantities of products each month, as well as the generation of indicators to support decision-making for inventory managers, such as reorder points and alerts.

Methodologically, various techniques and approaches from systems engineering are employed to develop this functional tool, which will help improve inventory management, optimize purchasing planning, and reduce the risk of stockouts.

GLOSARIO

Demanda: Cantidad de productos requeridos durante un período determinado, calculada a partir del comportamiento histórico de consumo o ventas.

Predicción de demanda: Proceso mediante el cual se estiman las cantidades futuras de productos utilizando modelos estadísticos o de aprendizaje automático basados en datos históricos.

Gestión de inventarios: Conjunto de actividades orientadas al control, almacenamiento, abastecimiento y seguimiento de los productos disponibles en una organización.

Inventario Conjunto de productos, materiales o recursos almacenados y disponibles para su uso, venta o distribución.

Desabastecimiento: Situación en la que un producto no se encuentra disponible en el inventario cuando es requerido.

Sistema de apoyo a la decisión: Herramienta informática diseñada para asistir a los usuarios en la toma de decisiones mediante el análisis de datos y la generación de información relevante.

Modelo de predicción: Algoritmo o método matemático utilizado para estimar valores futuros a partir de datos históricos y patrones identificados en la información.

Datos históricos: Registros de consumo, ventas, compras o movimientos de inventario ocurridos en períodos anteriores y utilizados para el análisis y la predicción.

Punto de reposición: Nivel de inventario a partir del cual se debe realizar un nuevo pedido para evitar el desabastecimiento.

Tiempo de entrega (Lead Time): Período que transcurre entre la realización de un pedido y la recepción efectiva de los productos solicitados.

Series de tiempo: Conjunto de observaciones registradas en orden cronológico que permiten analizar patrones, tendencias y comportamientos a lo largo del tiempo.

Aprendizaje automático (Machine Learning): Rama de la inteligencia artificial que permite a los sistemas aprender patrones a partir de datos y realizar predicciones sin ser programados explícitamente para cada situación.

Dominio de inventario: Contexto o sector específico en el que se gestionan inventarios, como retail, manufactura, logística, salud, restaurantes o comercio electrónico.

1 INTRODUCCIÓN

1.1 CONTEXTO

La gestión eficiente de inventarios supone un desafío constante en diversos sectores. Problemas como sufrir de debastabecimiento pueden surgir por distintos factores como retrados en la entrega por parte de los proveedores, variaciones inesperadas de la demanda, o deficiencias en los procesos de planificación. Estas situaciones, en muchos casos, se encuentran fuera del control de los administradores, lo que incrementa la complejidad para ellos a la hora de tomar decisiones relacionadas con el abastecimiento.

Actualmente, normalmente en muchas empresas se cuenta con un software para gestión de inventarios tipo ERP, con este software se administra la disponibilidad de los productos mediante el uso de diferentes tipos de movimientos de inventario:

Uno de los tipos de movimientos consiste en las entradas de inventario, las cuales responden a la adquisición de productos a través de proveedores y son registradas mediante facturas que incluyen información como fecha, proveedor y costo.

Por otro lado, están las salidas por consumo, las cuales representan la venta, distribución o consumo de los productos, registrando información relacionada con las cantidades entregadas y el destino de estas. Adicionalmente, existen salidas de inventario asociadas a sucesos como devoluciones, productos dañados, vencimientos, pérdidas o ajustes de inventario, se registra la cantidad de productos que deben de ser retirados del inventario junto con su respectivo motivo. Posteriormente, se realizan ajustes de inventario, los cuales pueden ser tanto positivos como negativos, con el fin de corregir diferencias entre las cantidades registradas en el sistema y las existencias reales, garantizando así la consistencia de la información.

En general, un buen análisis de estos movimientos resulta fundamental para comprender el comportamiento del consumo de productos y así mejorar los procesos de planificación del abastecimiento.

1.2 PLANTEAMIENTO DEL PROBLEMA

En diferentes entornos, existe una problemática en la que la gestión del inventario de productos se ve afectado debido a la falta de información precisa sobre la demanda mensual de los mismos, lo que dificulta la planificación adecuada del abastecimiento. En este contexto, surge la necesidad de contar con herramientas que permitan analizar los datos históricos de inventario y generar estimaciones de demanda que apoyen la toma de decisiones relacionadas con el abastecimiento.



Fig. 1. Esquema detallado de entradas, proceso y salidas del sistema.

1.3 JUSTIFICACIÓN DEL PROBLEMA

Este proyecto se justifica teniendo en cuenta que esta es una problemática que no se ha visto abordada a profundidad y continua siendo una dificultad para organizaciones de diferentes sectores. Además este proyecto permite aplicar conocimientos de la ingeniería de sistemas como análisis de datos, modelos de predicción y aprendizaje automático para la construcción de una herramienta que contribuya a mejorar los procesos de planificación y administración, generando beneficios tanto para las organizaciones y los usuarios finales.

1.3.1 IMPACTOS

Mejorar la disponibilidad de los productos mediante una mejor planificación de los inventarios, apoyar la toma de decisiones del personal encargado del abastecimiento, y fortalecer el uso de herramientas tecnológicas en el sector administrativo.

1.4 PROPUESTA DE SOLUCION

Con este proyecto se propone el desarrollo de un software que ayude a predecir la demanda de productos en diferentes dominios y contextos de gestión de inventarios. Este sistema se realizará tras analizar datos como historial de consumo, esto para poder estimar exactamente las cantidades necesarias de cada producto en periodos mensuales.

La solución implementará modelos de predicción de demanda que procesarán la información histórica para identificar patrones y en base a ellos, generar estimaciones futuras. A partir de

estas predicciones, el sistema podra proporcionar informacion relevante para la toma de decisiones, tales como cantidades recomendadas de compra, puntos de reposicion y posibles alertas de desabastecimiento.

Se utilizaran datos reales del año 2021 del sector salud como caso de estudio, que seran complementados con datasets con datos publicos de diferentes dominios esto para poder evaluar el comportamiento del sistema en diferentes contextos.

Adicionalmente, el sistema tendra en cuenta variables como tiempo de entrega de proveedores (lead time) y cantidad de productos disponible, con el proposito de lograr que el sistema sea lo mas preciso posible.

Esta informacion sera presentada en una interaz que permitira visualizar los resultados de manera comprensible, esto para facilitar su uso por parte del personal encargado de la gestion de inventarios.




Fig. 2. Esquema detallado de la propuesta de solución.

1.5 PREGUNTA DE INVESTIGACION

¿Cómo se puede diseñar e implementar un sistema de apoyo a la decisión que, mediante modelos de predicción de demanda, permita estimar las cantidades necesarias de productos en un sistema de gestión de inventarios?

1.5.1 PREGUNTAS DERIVADAS

¿Qué variables y datos históricos son necesarios para estimar la demanda mensual de productos?

¿Qué modelos de predicción de demanda son más adecuados para estimar el consumo o venta de productos en diferentes dominios?

¿Cómo debe estructurarse el proceso de análisis y procesamiento de datos para generar predicciones confiables?

¿Qué tipo de salidas debe generar el sistema (por ejemplo, cantidades estimadas, punto de reposición, alertas) para apoyar la toma de decisiones?

1.6 OBJETIVOS

1.6.1 OBJETIVO GENERAL

Desarrollar un sistema que le permita a los usuarios poder predecir cual va a ser la demanda mensual de productos mediante el análisis de datos históricos, para garantizar su correcta planificación y abastecimiento

1.6.2 OBJETIVOS ESPECIFICOS

Identificar las fuentes de datos relevantes, incluyendo el historial de consumo y las variables del inventario necesarias para la predicción de la demanda de productos.

Seleccionar modelos de predicción de demanda adecuados para estimar el consumo o venta mensual de productos en diferentes contextos de los inventarios.

Incorporar variables como el tiempo de entrega de proveedores y el punto de reposición dentro del sistema para complementar las estimaciones de demanda.

Diseñar un módulo de visualización que presente las predicciones de manera clara y comprensible para apoyar la toma de decisiones del usuario.

Evaluar el desempeño del sistema desarrollado mediante la realización de pruebas con datos históricos, con el fin de analizar la precisión de las predicciones generadas y verificar su utilidad en el apoyo a la toma de decisiones en la gestión del inventario.

1.7 RESTRICCIONES

El proyecto tiene como principal alcance el desarrollo de un sistema de apoyo a la decisión orientado a la predicción de la demanda de medicamentos críticos en una farmacia hospitalaria,

esto utilizando los datos históricos de consumo como principal fuente de información. El sistema permitirá estimar la cantidad mensual requerida de medicamentos mediante la implementación de modelos de predicción de demanda, integrando funcionalidades como visualización de resultados, generación de reportes y apoyo en la toma de decisiones relacionadas con la planificación del abastecimiento. Asimismo, el sistema proporcionará al usuario cálculos como el punto de reposición, con el fin de contribuir a una mejor organización y control de los recursos disponibles en los entornos hospitalario.

El desarrollo del proyecto presenta algunas restricciones que deben ser consideradas. En primer lugar, el sistema se basará en un conjunto de datos históricos reales de la Clínica Nuestra señora de los remedios limitado al año 2021, lo que puede afectar la capacidad del modelo para capturar comportamientos actuales o cambios en la demanda a lo largo del tiempo. Además, no se contará con integración en tiempo real con sistemas hospitalarios, por lo que las predicciones se realizarán sobre datos estáticos.

1.8 RECURSOS Y VIABILIDAD TECNICA

2 MARCO TEÓRICO

Para la construcción del estado del arte, se realizó una revisión de literatura en bases de datos académicas reconocidas, con el fin de identificar estudios relevantes relacionados con la predicción de demanda y la gestión de inventarios en el sector salud.

2.0.1 Criterios de inclusión

Se consideraron los siguientes criterios para la selección de los estudios:

- Trabajos disponibles en español o inglés.
- Publicaciones académicas en bases de datos como IEEE Xplore, Scopus, ScienceDirect, Google Scholar y repositorios institucionales.
- Estudios enfocados en gestión de inventarios.
- Investigaciones que utilicen modelos de predicción de demanda.
- Estudios que describan el diseño de sistemas informáticos de apoyo a la decisión.

2.0.2 Criterios de exclusión

Se excluyeron los estudios que cumplieran con las siguientes características:

- Estudios con más de 10 años de antigüedad.
- Documentos incompletos o resúmenes sin acceso al texto completo.

2.1 FUNDAMENTOS TEORICOS

2.1.1 Gestion de inventarios

La gestion de inventarios consiste en el proceso que se realiza sobre la mercancía para conocer la cantidad disponible, esto permitiendo analizar los niveles de existencia y la aproximación del consumo real.[1]

Los pasos básicos para realizar una correcta gestión de inventario consisten en: Compra del inventario, en el que los productos se entregan al almacén o punto de venta, Almacenamiento del inventario, en el que este se guarda hasta que se necesite y Aprovechamiento del inventario, en donde se controla la cantidad de productos que hay a la venta para finalmente enviarlo o venderlo a los clientes.[2]

2.1.1.1 Tipos de gestion de inventario:

Gestión periódica de inventarios Este método implica realizar un recuento físico del inventario a intervalos específicos. Se toma el inventario al inicio del periodo, se suman las nuevas compras y se deduce el inventario final para calcular el costo de las mercancías vendidas (COGS).[2]

Gestión de inventario de códigos de barras Utiliza un sistema que asigna un número único a cada producto. Permite asociar datos como proveedor, dimensiones del producto, peso y cantidad en stock.[2]

Gestión de inventario RFID Transmite de forma inalámbrica la identidad de un producto mediante un número de serie único. Mejora la eficiencia y visibilidad del inventario, facilitando el seguimiento de artículos.[2]

2.1.2 Prediccion de demanda

La prediccion de la demanda es un proceso que permite mejorar la gestion de los niveles de inventario mediante la utilizacion de datos historicos. Una correcta prediccion de la demanda le permite a las organizaciones el poder tomar decisiones mas inteligentes a la hora de manejar sus provisiones, evitando la falta o exceso de productos, de esta manera, aumentando tanto la satisfaccion del cliente como la creacion de estraregias de negocio mas efectivas a corto y largo plazo [3].

En los ultimos años, los mercados han evolucionado y se han vuelto cada vez mas exigentes en cuanto la calidad y precision de los servicios, es por eso, que muchas organizaciones se ha visto inclinadas a incluir el uso de nuevas herramientas y tecnologias como Inteligencia Artificial. Machine Learning o analisis predictivo, para automatizar y perfeccionar esta tarea, ya que los metodos actuales estaticos que son la norma en muchas empresas y organizaciones han empezado a quedar obsoletas para satisfacer las necesidades del mercado actual.[3], [4]

La principal debilidad de los modelos de inventario actuales es que al ser poco robustos, no toman en contemplacion diferentes factores externos de manera inteligente [4].

2.1.3 Series de tiempo

Las series temporales son usadas para analizar datos históricos recogidos en intervalos regulares, como ventas diarias o mensuales, para identificar patrones, tendencias estacionales y ciclos. Estos patrones se identifican mediante técnicas como gráficos ACF y PACF, tambien estos patrones sirven para ajustar modelos estadísticos o de aprendizaje automático (como ARIMA, SARIMAX o Prophet) que permiten proyectar valores futuros [5]

Se utilizan estos modelos para hacer predicciones, los datos se agrupan en intervalos (mensualmente) para reducir variabilidad y facilitar el análisis. Tras el análisis de datos, se ajustan

los modelos y se evalúan mediante métricas como el RMSE, para que las predicciones sirvan en la toma de decisiones de gestión y planificación de recursos

2.1.4 Modelos de predicción de demanda

2.1.4.1 Redes Neuronales Artificiales (RNA):

Las redes neuronales artificiales (RNA) son técnicas útiles para la previsión de la demanda, gracias a su capacidad para manejar datos no lineales y captar relaciones funcionales sutiles entre datos empíricos, incluso cuando las relaciones subyacentes son desconocidas o difíciles de describir.

2.1.4.1.1 Long Short-Term Memory (LSTM)

Las redes neuronales de memoria a largo y corto plazo o LSTM es un tipo de red neuronal que se ha demostrado eficaz en la predicción de series temporales, esta tecnica esta diseñada para procesar datos secuenciales y temporales que fue creada para superar las limitaciones de las redes neuronales tradicionales.[6].

Su funcionamiento se basa en una estrictura de memoria que permite a la red aprender y recordar información a lo largo del tiempo, lo que es especialmente útil para capturar dependencias a largo plazo en los datos. LSTM cuenta con las tres siguientes puertas:

Puerta de olvido (forget gate): Decide qué información se descarta. Esta se calcula mediante la función sigmoide, que toma como entrada el vector de entrada actual y el estado oculto anterior, de esta menra, generando un valor entre 0 y 1 para cada componente de la celda de la memoria.

$$f_t = \delta(W_f[h_{t-1}, X_t] + b_f) \quad (1)$$

Puerta de entrada (input gate): Decide qué información se almacena en la memoria. Tambien usa una funcion tanh para normalizar la informacion que pasa atraves de la red neuronal.

$$i_t = \delta(W_i[h_{t-1}, X_t] + b_i), \quad L_t = \tanh(W_c[h_{t-1}, X_t] + b_c) \quad (2)$$

Puerta de salida (output gate): Decide qué información se utiliza para generar la salida oculta actual.

$$o_t = \delta(W_o[h_{t-1}, X_t] + b_o) \quad (3)$$

La actualizacion del estado celular se realiza mediante:

$$C_t = f_t * C_{t-1} + i_t * L_t \quad (4)$$

Finalmente, la salida oculta se calcula aplicando la función $\tanh$ al estado celular y multiplicándolo por la puerta de salida como:

$$h_t = o_t * \tanh(C_t) \quad (5)$$

2.1.4.1.2 Gated Recurrent Unit (GRU)

GRU es modelo de predicción bastante parecido a LSTM, pero con una arquitectura mucho más simple, lo que la hace muchísimo más compacta y potencialmente menos costosa computacionalmente que una LSTM equivalente. Estas han demostrado tener éxito en diferentes aplicaciones relacionadas con datos secuenciales o temporales, principalmente si son secuencias largas. GRU reduce el número de tres redes compuestas distintas que usa LSTM en solo 2, esto mediante la combinación de la compuerta de entrada y la compuerta de olvido mediante una suma directa. Las compuertas de GRU se denominan: Compuerta de actualización y Compuerta de reinicio. [7]

El modelo GRU se presenta como:

$$h_t = g(Uh(r_t \odot h_{t-1}) + Wx_t + b_h) \quad (6)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \quad (7)$$

donde z_t es la compuerta de actualización, r_t es la compuerta de reinicio y $\tilde{h}_t$ es la propuesta de nueva información. Las dos compuertas se presentan como:

$$z_t = \sigma(U_z h_{t-1} + W_z x_t + b_z) \quad (8)$$

$$r_t = \sigma(U_r h_{t-1} + W_r x_t + b_r) \quad (9)$$

2.1.4.2 Modelos estadísticos y de Machine Learning tradicionales:

2.1.4.2.1 Regresión lineal

Los modelos de regresión son utilizados para resolver problemas de predicción, el objetivo de este modelo puede ser explicativo, donde se busca, por ejemplo, evaluar cómo ciertas variables independientes afectan a una variable dependiente, o predictivo, en el que se busca estimar el valor de la variable dependiente en función de las independientes [8].

Un modelo de regresión se expresa como:

$$y = (x_1, x_2, \dots, x_n)\beta + \epsilon \quad (10)$$

Existen distintas opciones para poder estimar un modelo de regresion, siendo las mas comunes: Regresion lineal y regresion logistica. La eleccion depende del tipo de variable dependiente que se tenga, si es una variable continua se utiliza regresion lineal, mientras que si se trata de una variable dicotomica se utiliza una variable dicotomica.

2.1.4.3 Modelos basados en árboles de decisión:

2.1.4.3.1 XGBoost

XGBoost se ha utilizado ampliamente en numerosos campos para lograr resultados de vanguardia (state-of-the-art) en tareas relacionadas con datos y predicción. Su funcionamiento consiste en un sistema de aprendizaje automatizado basado en el metodo de Tree Boosting que incluye un algoritmo de aprendizaje de arboles. EL Tree Boosting es un algoritmo de aprendizaje por conjuntos o ensemble learning, capaz de transformar varios clasificadores debiles en uno fuerte con el objetivo de obtener un mejor rendimiento en le clasificacion, es decir, se combinan multiples arboles para obtener un modelo mas potente. Un modelo tree boosting se escribe de la siguiente manera[9]:

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i), f_k \in F \quad (11)$$

Donde:

$$F = \{f(x) = w_{q(x)}\}(q : R^m \rightarrow T, w \in R^T) \quad (12)$$

Representa el espacio de los arboles de regresion o clasifiacion

2.2 ANTECEDENTES

2.2.1 Comparación de modelos de predicción de demanda

Debido a que existen diferentes modelos y tecnicas para la prediccion de la demanda, se realizo una revision de literatura de diferentes estudios que emplean los modelos mas utilizados para la prediccion de la demanda, esto con el fin de realizar el siguiente analisis comparativo para determinar cual es el mas adecuado para la prediccion de demanda en el presente proyecto, teniendo en cuenta ventajas, limitaciones y características como: tipo de datos utilizados, dominio de aplicación, tecnica de aplicacion, metricas de evaluacion y resultados obtenidos, dataset utilizado, entre otros.

TABLA I

Comparación de técnicas de predicción aplicadas a problemas de demanda y series de tiempo

Aspecto	Redes neuronales (ANN)	LSTM	Regresión lineal	GRU	XGBoost
Referencia	<i>Demand Forecasting Using Neural Network for Supply Chain Management</i>	<i>LSTM Model Based Demand Forecasting in Supply Chain Using Efficient Optimizer</i>	<i>Application of ABC Analysis and Linear Regression Model in Inventory Management</i>	<i>StockNet-GRU Based Stock Index Prediction</i>	<i>XGBoost-Based Demand Forecasting in Supply Chain Management Using Machine Learning Algorithm</i>
Datos utilizados	Datos históricos de ventas organizados como series de tiempo. Se emplean ventas mensuales de un filtro de combustible entre 2011 y 2013 para predecir la demanda de 2014.	Datos históricos de ventas organizados como series de tiempo. Incluyen fecha, unidades vendidas, ganancias y ubicación, seleccionando las variables relevantes para el entrenamiento.	Datos históricos de inventario y ventas. Incluyen información de productos, inventario, órdenes de compra y venta, cantidad y precio de venta, fecha, marcas, clasificación e impuestos.	Series de tiempo financieras correspondientes a precios históricos de apertura del índice bursátil CNX Nifty y de las 10 acciones con mayor correlación. Los datos se normalizan y organizan mediante ventanas deslizantes de 20 días.	Datos logísticos y de cadena de suministro relacionados con la demanda, incluyendo variables asociadas con proveedores y logística. Los datos se normalizan mediante Z-score y posteriormente se seleccionan las variables relevantes.
Dominio	Gestión de la cadena de suministro, control de inventarios, manufactura y distribución. También presenta aplicaciones en turismo, consumo eléctrico, supermercados y ventas.	Gestión de la cadena de suministro y predicción de demanda.	Gestión de inventarios, cadena de suministro y análisis de ventas.	Predicción de índices bursátiles, mercados financieros y análisis de series de tiempo.	Gestión de la cadena de suministro, predicción de demanda, logística y optimización de inventarios. El enfoque puede aplicarse a diferentes sectores que requieran pronósticos de demanda.
Técnica	Red neuronal <i>feed-forward</i> entrenada mediante <i>Backpropagation</i> . Se comparan Gradient Descent, Conjugate Gradient y Levenberg-Marquardt, siendo este último el de mejor desempeño.	Red neuronal recurrente LSTM con tres capas, regularización mediante Dropout y optimizadores Adam y SGD. Se experimenta con épocas, tasa de aprendizaje, tamaño de lote y longitud de secuencia.	Modelo de regresión lineal para identificar tendencias en cantidad y precio de venta. Utiliza Gradient Descent para minimizar el error cuadrático, después de realizar limpieza de datos y selección de variables.	Red neuronal recurrente GRU integrada en la arquitectura StockNet. Utiliza ventanas deslizantes de 20 días, optimizador Adam, activación ReLU y datos normalizados entre 0 y 1.	El proceso incluye normalización Z-score, selección de características mediante un Algoritmo Genético, predicción mediante XGBoost y optimización de hiperparámetros mediante Particle Swarm Optimization (PSO).
Métricas	Error absoluto de pronóstico (<i>Forecasting Error</i>) y porcentaje de error, comparando los valores pronosticados con los valores reales.	RMSE para medir la diferencia entre valores reales y predichos. También se compara el tiempo promedio por época para evaluar la eficiencia computacional.	Coefficiente de determinación (R^2). El estudio reporta un valor de 70,57 % para la predicción de la cantidad vendida y cercano al 80 % para el precio de venta.	RMSE, MAE y MAPE. También se considera el tiempo de ejecución y se utiliza la prueba estadística de Wilcoxon para validar diferencias entre modelos.	MAE, RMSE y coeficiente de determinación. Se compara el desempeño de XGBoost con SARIMA, Decision Tree (DT) y Random Forest (RF).
Dataset	Datos reales de consumo mensual de un filtro de combustible perteneciente a una empresa manufacturera. Contiene registros mensuales entre 2011 y 2013 para entrenamiento y validación.	<i>Sales Dataset</i> con información histórica de ventas utilizada para entrenar y evaluar el modelo.	Dataset de inventario de una tienda de comestibles (<i>grocery store</i>) con información de productos, inventario y ventas. Después del preprocesamiento se utilizan aproximadamente 60 observaciones correspondientes a dos meses.	Índice bursátil CNX Nifty y las 10 acciones más correlacionadas del National Stock Exchange (NSE) de India, obtenidos desde Yahoo Finance. Contiene 5.904 días de negociación entre abril de 1996 y enero de 2020.	Dataset de demanda de cadena de suministro con información relacionada con logística y proveedores. Se utiliza para entrenar y evaluar el modelo de predicción.
Comentario / reseña	Las ANN permiten modelar relaciones no lineales y presentan resultados favorables frente a métodos tradicionales de series de tiempo. Son útiles para predicciones de corto plazo, aunque requieren suficiente información y ajuste de parámetros.	LSTM constituye una alternativa eficaz para la predicción de demanda debido a su capacidad para capturar dependencias temporales de largo plazo. Puede contribuir a la optimización de inventarios y a la toma de decisiones en la cadena de suministro.	La regresión lineal permite identificar y proyectar tendencias generales de ventas e inventario y presenta una menor complejidad. Sin embargo, tiene limitaciones para representar relaciones complejas y eventos extraordinarios.	GRU permite capturar dependencias temporales y presenta resultados favorables en la predicción de series de tiempo. Sin embargo, el estudio analizado se desarrolla en el dominio financiero, por lo que su aplicación a inventarios requiere evaluación adicional.	XGBoost presenta capacidad para modelar relaciones complejas y puede utilizarse para apoyar la planificación de inventarios, reducir costos y optimizar operaciones en la cadena de suministro.

Fuente: Elaboración propia a partir de los estudios revisados.

2.3 ESTANDARES DE INGENIERIA APLICABLES

3 DISEÑO Y DESARROLLO

3.1 Enfoque metodológico

3.1.1 Gestión del Proyecto (Planeación)

3.1.2 Ciclo de Vida del Software (Ejecución)

3.2 Procesos Técnicos y Diseño (ISO/IEC/IEEE 12207)

3.2.1 Identificación de Stakeholders

3.2.2 Elicitación de Requisitos

3.2.3 Especificación de Requisitos de Software (SRS)

3.2.4 Diseño de la Arquitectura

3.2.5 Escenarios Arquitecturales

3.2.6 Análisis de Alternativas y Decisiones de Diseño (ADRs)

3.2.7 Representación de la Arquitectura (Modelo C4)

3.2.8 Diseño Detallado

3.2.9 Modelo de Datos

3.2.10 Diseño UX/UI

3.2.11 Análisis de Amenazas y Diseño Seguro

3.3 Construcción, Integración y Despliegue

3.4 Plan de Verificación y Validación

4 RESULTADOS